



Tempest

ACADEMY

Conference
2023



ML, AutoML, XAI e AML na Detecção de Malwares Android: desafios e lições

Diego Kreutz

diegokreutz@unipampa.edu.br



Diego Kreutz (1)



Engenharia de Software




Diego Kreutz (2)

- falar pouco
- inovar
- simplificar (KISS na área de crypto)
- fazer (ação)
- objetividade
- positividade
- resolver problemas (focar em ideias e alternativas)

Diego Kreutz (3)


 Tempest
[ACADEMY]
Conference



Diego Kreutz (4)

1. Alegrete (07:00)
2. Uruguaiana
3. Porto Alegre
4. São Paulo
5. Recife (02:00)

Viagem: 19h



Esta palestra

- É sobre pesquisas aplicadas
- Trajetória, desafios, lições e *insights*
- 8 ferramentas / sistemas desenvolvidos



Universidade Federal do Pampa



UFAM



Tempest


ACADEMY

Conference

Machine Learning

O processo típico

Processo Típico de *Machine Learning*




The diagram illustrates the data science process flow and the role of domain experts. It shows the following components and interactions:


- Product team**: Interacts with **Domain Experts** through **Insights** (orange arrow pointing right) and **Needs** (blue arrow pointing left).
- Domain Experts**: Represented by an icon of two people, they provide input to **Sensors**, **Experiments**, and **Big Data**.
- Product /Service**: Receives input from the **Product team** and provides input to **Consumers**.
- Consumers**: Represented by an icon of four people, they provide input to **Big Data**.
- Sensors**: Represented by a thermometer icon, they provide input to **Big Data**.
- Experiments**: Represented by a flask icon, they provide input to **Big Data**.
- Big Data**: Represented by a database icon, it provides input to the **Data Scientist**.
- Data Scientist**: Represented by an icon of a person at a laptop, they provide input to **Feature Construction**.
- Feature Construction**: Represented by an icon of three blocks, it provides input to the **Data Scientist**.
- Profundo know-how do domínio**: A large speech bubble containing the text "Profundo know-how do domínio" (Deep domain know-how) is connected to the **Domain Experts** and the **Data Scientist** via a red arrow labeled **Bottleneck**.



Processo Típico de *Machine Learning*



Processo Típico de *Machine Learning*





Tempest


ACADEMY

Conference


AutoML

Objetivos


AutoML: objetivos (1)



AutoML: objetivos (2)



AutoML: pipeline



AutoML: pipeline (ferramentas)



Exemplos de
ferramentas de
propósito geral

AutoML: pipeline (???)




Existem **otimizações específicas** ao domínio?
As soluções existentes **incorporam recursos de transparência e interpretabilidade?**

AutoML: pipeline


Investigar as etapas de
AutoML para domínio
específico.
Desenvolver um
***framework* de AutoML**
especializado para o
domínio.




AutoML: pipeline




AutoML: pipeline



AutoML: pipeline



AutoML: pipeline almejado



AutoML: níveis de automação

	Systems	What is automated?	Access to ML	Efficiency of data scientist
Level 6	???			
Level 5	ComposeML + Level 4 systems			
Level 4	Darpa D3M, MLbazaar, RapidMiner			
Level 3	ATM, Rafiki, Amazon, AutoML, DataRobot, H2O, AUTO-WEKA		Processo Típico de <i>Machine Learning</i>	
Level 2	Scikit-Learn, Keras, Tensorflow, WEKA, ORANGE, Pytorch			
Level 1	Basic implementation of Decision Tree, KMeans, SVM etc.			
Level 0	Programming languages like python, Java, C++			



AutoML: níveis de automação

	Systems	What is automated?	Access to ML	Efficiency of data scientist
Level 6	???	TF PE AML (FE ML ATV) RSR		
Level 5	ComposeML + Level 4 systems	PE AML (FE ML ATV)		
Level 4	Darpa D3M, MLbazaar, RapidMiner	AML (FE ML ATV)		
Level 3	ATM, Rafiki, Amazon, AutoML, DataRobot, H2O, AUTO-WEKA	AML (ML ATV)		
Level 2	Scikit-Learn, Keras, Tensorflow, WEKA, ORANGE, Pytorch	(ML) (ATV)		
Level 1	Basic implementation of Decision Tree, KMeans, SVM etc.	(ML)		
Level 0	Programming languages like python, Java, C++			

ML e ATV
(exploração, teste
e validação de
modelos
alternativos)
automatizados
separadamente



AutoML: níveis de automação

	Systems	What is automated?	Access to ML	Efficiency of data scientist
Level 6	???			
Level 5	ComposeML + Level 4 systems			
Level 4	Darpa D3M, MLbazaar, RapidMiner			
Level 3	ATM, Rafiki, Amazon, AutoML, DataRobot, H2O, AUTO-WEKA			
Level 2	Scikit-Learn, Keras, Tensorflow, WEKA, ORANGE, Pytorch			
Level 1	Basic implementation of Decision Tree, KMeans, SVM etc.			
Level 0	Programming languages like python, Java, C++			

ML e ATV
automatizados em
conjunto



AutoML: níveis de automação

	Systems	What is automated?	Access to ML	Efficiency of data scientist
Level 6	???	TF PE AML FE ML ATV RSR		
Level 5	ComposeML + Level 4 systems	PE AML FE ML ATV		
Level 4	Darpa D3M, MLbazaar, RapidMiner	AML FE ML ATV		
Level 3	ATM, Rafiki, Amazon, AutoML, DataRobot, H2O, AUTO-WEKA	AML ML ATV		
Level 2	Scikit-Learn, Keras, Tensorflow, WEKA, ORANGE, Pytorch	ML ATV		
Level 1	Basic implementation of Decision Tree, KMeans, SVM etc.	ML		
Level 0	Programming languages like python, Java, C++			

Formulação de
Tarefa (FT),
Engenharia de
Predição (PE),
Recomendação de
Sumário e
Resultados (RSR)



AutoML: níveis de automação

	Systems	What is automated?	Access to ML	Efficiency of data scientist
Level 6	???			
Level 5	ComposeML + Level 4 systems			
Level 4	Darpa D3M, MLbazaar, RapidMiner			
Level 3	ATM, Rafiki, Amazon, AutoML, DataRobot, H2O, AUTO-WEKA			
Level 2	Scikit-Learn, Keras, Tensorflow, WEKA, ORANGE, Pytorch			
Level 1	Basic implementation of Decision Tree, KMeans, SVM etc.			
Level 0	Programming languages like python, Java, C++			

Objetivo:
investigar,
desenvolver e
aplicar AutoML
em domínio
específico





Tempest


ACADEMY

Conference

AutoML: Estágios do Pipeline

De **Aquisição** até
Otimização de
Hiperparâmetros

AutoML: pipeline almejado



Datasets: a importância dos dados



ACADEMY
Conference

Top 10 Reasons Why AI Projects Fail

1. Applying application development approaches to **data-centric** AI
3. Lack of sufficient **quantity** of data
4. Lack of sufficient **quality** of data
6. Misalignment of real world data

85% dos
projetos de
ML falham





ACADEMY

Conference

Datasets: Disponibilidade e Reprodutibilidade

Descobertas e desafios

Datasets: trabalhos selecionados

38 trabalhos divididos
em 4 grupos



- **Grupo 1:** citados por algum *survey* ou revisão sistemática;
- **Grupo 2:** com 40 (ou mais) citações segundo o Google Scholar;
- **Grupo 3:** publicados nos principais periódicos ou conferências da área de segurança (segundo o *Guide2Research.com*);
- **Grupo 4:** publicados em conferências/journals específicas da área de inteligência artificial

Datasets: trabalhos selecionados

Quais as **fontes de dados utilizadas** na construção do *dataset*?

A **fonte de dados**, que serviu como origem para os dados, é **acessível**? Se sim, de qual forma?

Quais **informações específicas** (e.g., quantidade, nomes, versões) sobre as aplicações Android que compõem o *dataset* são mencionadas no trabalho?



Datasets: disponibilidade & atualização

Datasets e Repositórios de APKs	Atualização	Acesso
Ether Malware Analysis Dataset	[2008-2012]	Disponível
Contagio Malware Dump, CIC-AAGM2017, MudFlow, Android Botnet, M0Droid, GaziBenignApp, Heldroid	[2013-2017]	
Contagio Mobile, Android Permissions Dataset, VirusShare, CICInvesAndMal2019 , TheZoo, AndroMalShare, Koodous, Drebin-215, Dataset of Android Permissions, CICMalDroid 2020 , Android Malware and Normal Permissions Dataset, Android Malware and Benign Application Dataset, PARUDroid, Comodo Cloud Security Center, Wang's Repository , Drebin4000 and AMD6000	[2018-2021]	
MobileSandbox project (MobWorm)	Atualização Não Encontrada	Restrito
CIC-AndMal2017 , AndroZoo, Andro-AutoPsy, Andro-Dumpsys, Andro-Profiler, Andro-Tracker	[2013-2017]	
UpDroid, Contagio Mini Dump, COVID19 Apps, CCCS-CIC-AndMal-2020	[2013-2018]	
DroidKin	Atualização Não Encontrada	Indisponível
The Drebin Dataset, Android Malware Genome Project	[2008-2012]	
Android PRAGuard Dataset, PlayDrone Project	[2013-2017]	
McAfee, Inter-Component Communication (IcRE) Repository, New Malware Families 2015, Virus Total Malware Service Intelligence, Kharon Malware Dataset	Atualização Não Encontrada	

Disponível



Restrito

Indisponível

Datasets: disponibilidade & atualização

Datasets e Repositórios de APKs	Atualização	Acesso
Ether Malware Analysis Dataset	[2008-2012]	84 fontes de dados
Contagio Malware Dump, CIC-AAGM2017, MudFlow, Android Botnet, M0Droid, GaziBenignApp, Heldroid	[2013-2017]	
Contagio Mobile, Android Permissions Dataset, VirusShare, CICInvesAndMal2019, TheZoo, AndroMalShare, Koodous, Drebin-215, Dataset of Android Permissions, CICMalDroid 2020, Android Malware and Normal Permissions Dataset, Android Malware and Benign Application Dataset, PARUDroid, Comodo Cloud Security Center, Wang's Repository, Drebin4000 and AMD6000	[2018-2021]	
MobileSandbox project (MobWorm)	Atualização Não Encontrada	
CIC-AndMal2017, AndroZoo, Andro-AutoPsy, Andro-Dumpsys, Andro-Profiler, Andro-Tracker	[2013-2017]	Restrito
UpDroid, Contagio Mini Dump, COVID19 Apps, CCCS-CIC-AndMal-2020	[2013-2018]	
DroidKin	Atualização Não Encontrada	
The Drebin Dataset, Android Malware Genome Project	[2008-2012]	Indisponível
Android PRAGuard Dataset, PlayDrone Project	[2013-2017]	
McAfee, Inter-Component Communication (IcRE) Repository, New Malware Families 2015, Virus Total Malware Service Intelligence, Kharon Malware Dataset	Atualização Não Encontrada	

Datasets: disponibilidade & atualização

Mais de 40% possui
acesso restrito ou
está **indisponível**

Datasets e Repositórios de APKs	Atualização	Disponibilidade
Ether Malware Analysis Dataset	[2008-2017]	Restrito
Contagio Malware Dump, CIC-AAGM2017, MudFlow, Android Botnet, M0Droid, GaziBenignApp, Heldroid	[2013-2017]	
Contagio Mobile, Android Permissions Dataset, VirusShare, CICInvesAndMal2019, TheZoo, AndroMalShare, Koodous, Drebin-215, Dataset of Android Permissions, CICMalDroid 2020, Android Malware and Normal Permissions Dataset, Android Malware and Benign Application Dataset, PARUDroid, Comodo Cloud Security Center, Wang's Repository, Drebin4000 and AMD6000	[2018-2020]	
MobileSandbox project (MobWorm)	Atualização Não Encontrada	Restrito
CIC-AndMal2017, AndroZoo, Andro-AutoPsy, Andro-Dumpsys, Andro-Profiler, Andro-Tracker	[2013-2017]	
UpDroid, Contagio Mini Dump, COVID19 Apps, CCCS-CIC-AndMal-2020	[2013-2018]	
DroidKin	Atualização Não Encontrada	Indisponível
The Drebin Dataset, Android Malware Genome Project	[2008-2012]	
Android PRAGuard Dataset, PlayDrone Project	[2013-2017]	
McAfee, Inter-Component Communication (IcRE) Repository, New Malware Families 2015, Virus Total Malware Service Intelligence, Kharon Malware Dataset	Atualização Não Encontrada	

Datasets: disponibilidade & atualização

Datasets e Repositórios de APKs	Atualização	Acesso
Ether Malware Analysis Dataset	[2008-2012]	Disponível
Contagio Malware Dump, CIC-AAGM2017, MudFlow, Android Botnet, M0Droid, GaziBenignApp, Heldroid	[2013-2017]	
Contagio Mobile, Android Permissions Dataset, VirusShare, CICInvesAndMal2019, TheZoo, AndroMalShare, Koodous, Drebin-215, Dataset of Android Permissions, CICMalDroid 2020, Android Malware and Normal Permissions Dataset, Android Malware and Benign Application Dataset, PARUDroid, Comodo Cloud Security Center, Wang's Repository, Drebin4000 and AMD6000	[2018-2021]	
MobileSandbox project (MobWorm)	Atualização não Encontrada	
CIC-AndMal2017, AndroZoo, Andro-AutoPsy, Andro-Dumpsys, Andro-Profiler, Andro-Tracker		
UpDroid, Contagio Mini Dump, COVID19 A		
DroidKin		
The Drebin Dataset, Android Malware Gene		
Android PRAGuard Dataset, PlayDrone Pro		
McAfee, Inter-Component Communication (		
New Malware Families 2015, Virus Total Ma		
Kharon Malware Dataset		

Quase 60% está **disponível**,
porém **limitados** e/ou **defasados**

Datasets: disponibilidade & atualização



Desafio: como encontrar
ou construir *datasets*
representativos e
atualizados?

Datasets: disponibilidade & atualização

Idéia: pesquisa exploratória de *datasets* de domínio público ou acessíveis via solicitação.



Datasets: disponibilidade & atualização

Idéia: pesquisa exploratório de *datasets* de domínio público ou acessíveis via solicitação.



Resultado: mais de 100 *datasets* mapeados. **Problemas:**
defasagem e
representatividade.



Datasets: reprodutibilidade

3 aspectos observados



1. Referência à **origem das amostras** utilizadas (e.g., *dataset* ou APKs em repositório)
2. **Quantidade de amostras** utilizadas em cada experimento
3. **Descrição** da forma **como** o conjunto de dados próprio do trabalho **foi criado**

Datasets: reprodutibilidade

Resultado: 100% dos trabalhos falham em apresentar informações fundamentais acerca dos *datasets* criados ou utilizados



Datasets: conclusão

Lição: investigue e analise detalhadamente antes de utilizar ou assumir que *datasets* existentes são confiáveis, atualizados ou representativos



Datasets: conclusão

Lição: investigue e analise **detalhadamente** antes de utilizar ou assumir que *datasets* existentes são confiáveis, atualizados ou representativos



Ideia: construir um sistema para **gerar datasets atualizados, representativos e auto-contidos.**





Tempest

ACADEMY

Conference

Datasets: Geração

Estágio 1: ADBuilder

Estágio 2: AMGenerator & AMExplorer

Datasets: geração (objetivos)


- Quantidade representativa de amostras (e.g., 1M)
- Quantidade significativa de características
- Sistematização e automação do processo
- Reprodutibilidade
- Metadados atualizados (e.g., VirusTotal)
- Aplicativos variados e também atuais



ADBuilder




Datasets: ADBuilder (concepção)




Datasets: ADBuilder (implementação)

A partir da assinatura SHA256, realiza o download do APK do AndroZoo (19M+ APKs)



Datasets: ADBuilder (implementação)

Utilização do AndroGuard para extração de características estáticas



Datasets: ADBuilder (implementação)



Dúvida: por que o
AndroGuard?

Datasets: ADBuilder (implementação)


AndroGuard é uma das ferramentas de extração de características mais completa



Ferramenta	Permissões		Intents		API		Componentes do APP		Opcode	
	B.	M.	B.	M.	B.	M.	B.	M.	B.	M.
Androguard	144	43	292	53	3470999	658404	934	91	13376816	2614284
PHP APK Parser	140	39	74	13	0	0	565**	46**	0	0
Mobile Audit	144	33	*	*	0	0	846*	91*	0	0
PScout	9	0	0	0	0	0	0	0	0	0


Datasets: ADBuilder (implementação)

VirusTotal (VT) contém hoje mais de 60 *scanners* e retorna os dados da **última análise**




Datasets: ADBuilder (implementação)

Os apps *Smart Gallery 1.1* e *Smart Cleaner* foram classificados como **benignos em 2019/2020**. Em 2022, **mais de 18 scanners do VT classificaram como malware** os dois APKs.



Datasets: ADBuilder (implementação)

Geração recebe como entrada **dados do download**, **extração e metadados do VT** para gerar um *dataset* binário



Desafios identificados ao final do primeiro estágio

- Garantir **rotulação atualizada** (VT possui *cache* de dados)
- Criar *datasets* de **metadados** (mais ricos em informação)
 - permitir múltiplos tipos de análises
- Gerar *datasets* binários e discretos
- Permitir ao usuário personalizar a composição do *dataset*

Datasets: AMGenerator e AMExplorer

Criação das
ferramentas
AMGenerator e
AMExplorer



Datasets: AMGenerator e AMExplorer



Mas por que separar a
ADBuilder em duas novas
ferramentas?

Datasets: AMGenerator e AMExplorer



Mas por que separar a
ADBuilder em duas novas
ferramentas?


- **Desafio 1:** escalar a rotulação
 - limitações de contrato
 - limitação por chave de API
- **Desafio 2:** personalizar a escalar a geração
 - múltiplas fontes de informação

Datasets: AMGenerator e AMExplorer


Metadados para rotulação / análise e criação personalizadas, sistematizadas e avançadas.

AMGenerator


Aquisição de APKs



Extração




Rotulação




AMExplorer

Criação da base de dados



Datasets: AMGenerator


ANÁLISE



Fluxo de **coleta** de **metadados** para rotulação com **análise** e **reanálise**


Datasets: AMGenerator

ANÁLISE



Datasets: AMGenerator

ANÁLISE



AMGenerator
(agora): **maior**
que data
definida pelo
usuário

Datasets: AMGenerator

ANÁLISE

Mais de **95% do APKs** estão indo para **reanálise**

01 janeiro de 2023?



Resultado da análise

Sim

Não

REANÁLISE

3


Fila de espera
(24h)

2

Solicita
reanálise

Desafio: escalar as reanálises com o VT (**menos de 250 reanálises** / dia / chave de API)

Datasets: AMExplorer



- (1) metadados do AndroZoo
- (2) metadados da extração
- (3) atributos da extração
- (4) metadados do VT

Construção parametrizada e geração de múltiplos variações de *datasets*

Datasets: AMGenerator e AMExplorer

- **Objetivo final:** gerar *datasets* expressivos (e.g., 1M+ amostras e 200K+ características)
- **Desafio:** tempo e recursos necessários para a geração

Principal gargalo: geração dos metadados para rotulação (VT)

Datasets: AMGenerator e AMExplorer

- **Status (1):** MH-100K já publicado
 - 101975 amostras
 - 24500+ características

MH-100K está sendo utilizado e analisado por equipe técnica interna da Motorola



Datasets: AMGenerator e AMExplorer

- **Status (2):** MH-1M+ em processamento (**5+ meses**)

Download



2.699.949

Extração



1.987.684

VirusTotal



1.492.366

Datasets: AMGenerator e AMExplorer


- **Status (2):** MH-1M+ em processamento (**5+ meses**)

Download



2.699.949

Ex



1.987.684



1.492.366

Desafio: tempo e recursos computacionais

Datasets: usar IA generativa (?)



Podemos utilizar **IA generativa** para aumentar *datasets* e também detectar *malwares* mutantes?


Datasets: usar IA generativa (?)

DroidAugmentor:
utilizar Redes Neurais
Artificiais para
aumentar e variar
datasets



Datasets: DroidAugmentor


Ferramenta de treinamento e parametrização de cGANs para geração de dados sintéticos



Datasets: DroidAugmentor


Permite ao usuário:

- executar múltiplas campanhas automaticamente
- observar métricas de similaridades
- observar métricas de aplicabilidade
- observar a matriz de confusão de todas as dobras
- observar os gráficos da curva de aprendizagem
- observar os mapas de calor




Datasets: DroidAugmentor


Drebin-215: mapa de calor das características dos dados
(Real Maligno e Sintético Maligno)




(a) Real M.



(b) Real B.




(c) Sint. M.




(d) Sint. B.

Datasets: DroidAugmentor


Drebin-215: mapa de calor das características dos dados
(Real Benigno e Sintético Benigno)




(a) Real M.



(b) Real B.



(c) Sint. M.



(d) Sint. B.

Desafios: complexidade e custo computacional

- Trabalhar com cGANs é **complexo** e exige **conhecimento específico** (**solução:** criação de um *framework*)
- Redes Neurais Artificiais podem ser complexas e **demandar recursos computacionais** substanciais

Datasets: DroidAugmentor

Status: *framework* em desenvolvimento

- 6 modelos totalmente diferentes
- mais de 30 variações de arquitetura e topologias



Datasets: como escalar?



Uma plataforma
(serviço) para escalar
a execução de
ferramentas de IA
generativa como a
DroidAugmentor?


Datasets: como escalar?

AutoDroid: solução modular para **escalar** **execução** de ferramentas de **IA** **generativa**




Datasets: AutoDroid


Arquitetura de microsserviços baseados em containers Docker



AutoML: pipeline almejado



AutoML: pipeline almejado






ACADEMY

Conference

AutoML: Preparação dos Dados

Como as ferramentas de
AutoML se comportam em
um **domínio específico**?

AutoML: ferramentas



AutoML: pré-processamento


'Feature1': [1, 0, 1, 1],
'Feature2': [False, False, True, True],
'Feature3': [true, false, true, false],
'Downloads': [10, 100, 2, 9],
'Label': ['Mal', 'Ben', 'Ben', 'Mal'],
'SHA256': ['8994a47e0315feb75c1a9...']

Desafio: ferramentas
de propósito geral
falham ao tratar
determinados tipos de
dados / valores


Alternativa: combinar diferentes técnicas

- Combinar métodos de *label encoding* e *one-hot-encoder*
- Identificar assinaturas criptográficas para remover duplicatas
- Remover assinaturas criptográficas
- Transformar *strings* do tipo “true, false”
- Identificar e transformar tipos de dados do *dataset*

AutoML: pipeline almejado



AutoML: pipeline almejado





Tempest

ACADEMY

Conference

AutoML: Engenharia de Características

Foco inicial: **seleção de características** específica ao domínio e **transparência**

AutoML: seleção de características

Existem **muitos métodos especializados**
de seleção de características.




Qual o melhor?
Como avaliar métodos de
seleção de características
de forma sistemática?

AutoML: seleção de características

Framework para **avaliação**
sistemática e
reprodutibilidade de
métodos de seleção



FS3E: seleção de características



FS3E: seleção de características

Entradas

Problema 1: implementação dos métodos de seleção de características **raramente** está **disponível**

Etapas

Métodos de
seleção de
características

Modelos de
aprendizado de
máquina

Visualização

Saídas

Datasets de
características
selecionadas

Métricas de
avaliação

Gráficos das
métricas

FS3E: seleção de características

Entradas

Problema 1: **implementação** dos métodos de seleção de características **raramente** está **disponível**

Problema 2: os **métodos** são tipicamente **comparados** apenas com **técnicas clássicas** (e.g., PCA, SQ) de seleção de características

Etapas

Saídas

Datasets de
características
selecionadas

Métricas de
avaliação

Gráficos das
métricas

FS3E: seleção de características

Entradas


Problema 1: **implementação** dos métodos de seleção de características **raramente** está **disponível**

Problema 2: os **métodos** são tipicamente **comparados** apenas com **técnicas clássicas** (e.g., PCA, SQ) de seleção de características


Problema 3: os trabalhos **utilizam** apenas **poucos datasets** na avaliação e a maioria deles é **defasado** e pouco representativo.

Saída


FS3E (v2): seleção de características



FS3E (v2): seleção de características



FS3E (v2): seleção de características



FS3E (v2): seleção de características

Dataset	Tipo Carac.	Amostras	Cars.	% M / B
Adroit	P	11476	166	29.8 / 70.2
Androcrawl	P, I, CAPI	96732	141	10.5 / 89.5
Android_Per	P	26864	151	66.21 / 33.79
DefenseDroid	P, I	11975	2938	50.1 / 49.9
Drebin-215	P, CAPI, CS, I	15036	215	37 / 63
KronoDroid	P, CS	78137	383	53 / 47

FS3E (v2): seleção de características

Dataset	Tipo Carac.	Amostras	Cars.	% M / B
Adroit	P	11476	166	29.8 / 70.2
Androcrawl	<i>Datasets desbalanceados</i> <i>Datasets com</i> <i>desbalanceamento inverso</i> <i>Datasets balanceados</i>			10.5 / 89.5
Android_Per				66.21 / 33.79
DefenseDroid				50.1 / 49.9
Drebin-215				37 / 63
KronoDroid	P, CS	78137	383	53 / 47

FS3E (v2): seleção de características

Dataset	ROC AUC	# Car.	% R.
Adroit	83.69	29	82.63
Androcrash	94.56	29	79.58
DefenseDroid	88.57	32	98.89
Drebin-2	92.59	20	90.74
KronoDroid	92.57	32	88.85

FSDroid e
SemiDroid
atingem **altas**
taxas de
redução e boas
taxas de
classificação

FS3E (v2): seleção de características

Dataset	Tipo Carac.	Amostras	Cars.	% M / B
Adroit	P	11476	166	29.8 / 70.2
Andro	Comparação detalhada entre os métodos	96732	1	5
Androi		26864	1	79
Defese		11975	29	9
Drebin-215		15036	2	
KronoDroid	P, CS	78137	383	53 / 47



FS3E (v2): seleção de características

*Dataset Drebin-251 e FSDroid com **threshold** de 30*

PCA %	# car.	Acurácia	Recall	AUC
5%	10	89.40	86.18	93.33
10%	20	89.40	86.18	93.33
20%	41	89.40	86.18	93.33
30%	62	95.52	93.23	98.68
40%	83	97.10	95.19	99.45
50%	104	97.37	94.74	99.61

FSDroid	62	98.23	96.95	97.96
---------	-----------	--------------	--------------	--------------


FS3E (v2): seleção de características

PCA %	# car.	Acurácia	Recall	AUC
5	10	89.40	86.18	93.33
10	20	89.40	86.18	93.33
				93.33
				98.68
				99.45
				99.61

Objetivo (em andamento): incorporar também técnicas clássicas no *framework* (FS3E) de métodos de seleção de características

FSDroid	62	98.23	96.95	97.96
---------	----	-------	-------	-------

AutoML: pipeline almejado



AutoML: transparência



AutoML: transparência

All Features



Feature Selection



Final Features



Desafio: qual foi o conjunto de características gerado e/ou selecionado?

AutoML: transparência

```
INFO: [2023-10-08 18:26] Performing feature selection
INFO: See the selected features at: results\Features_Selected_20231008_182631.csv
DEBUG:      SEND_SMS_1  READ_PHONE_STATE_1  GET_ACCOUNTS_1  ...  BLUETOOTH_1  RE
AD_CALENDAR_1  READ_CALL_LOG_1
```


```
INFO: [2023-10-08 18:26] Performing feature selection
INFO: See the selected features at: results\Features_Selected_20231008_182631.csv
DEBUG:      SEND_SMS_1  READ_PHONE_STATE_1  GET_ACCOUNTS_1  ...  BLUETOOTH_1  RE
AD_CALENDAR_1  READ_CALL_LOG_1
```

Final Features




Alternativa: modificar as ferramentas para registrar e visualizar os conjuntos de características

AutoML: pipeline almejado



AutoML: pipeline almejado





ACADEMY

Conference

AutoML: Seleção e Treinamento de Modelos

Foco inicial: **complexidade,**
comportamento e
otimização de
hiperparâmetros

Top 10 Reasons Why AI Projects Fail

7. Underestimating time and cost of the data component of AI projects

85% dos
projetos de
ML falham



AutoML: complexidade dos modelos



Qual o **comportamento teórico e empírico** dos **modelos** para *datasets* de variados tamanhos (amostras & características)?


AutoML: complexidade dos modelos

Entender o comportamento dos modelos e como as escolhas no pipeline de AutoML podem afetar em termos de métricas e recursos computacionais



AutoML: complexidade dos modelos


Gradient Boosting



a partir de 8k,
o número de
amostras
tende a gerar
um consumo
de recursos
maior

AutoML: complexidade dos modelos


Decision Tree



de
características
tem um custo
computacional
ligeiramente
maior

AutoML: complexidade dos modelos

Extra Trees



de características aumenta mais significativamente o consumo de recursos

AutoML: desempenho dos modelos

Modelo	Acurácia	Precisão	Recall
Gradient Boosting	0.93	0.92	0.85
Extra Trees	0.96	0.96	0.93
Decision Tree	0.95	0.94	0.93

Extra Trees apresentou **melhor desempenho** e **menor custo computacional**

AutoML: complexidade dos modelos

Insight: bons métodos de
seleção de
características podem
beneficiar o pipeline de
AutoML e modelos
baseados em **Extra Trees**,
por exemplo



AutoML: otimização de hiperparâmetros




O **caso emblemático** de ferramentas como o AutoGluon.

AutoML: otimização de hiperparâmetros



Hiperparâmetros
pré-definidos ou
selecionados
dinamicamente, em
tempo de execução?

AutoML: otimização de hiperparâmetros



Estado da arte (HPO)
versus otimização
manual com *Grid*
Search




AutoML: otimização de hiperparâmetros

AutoGluon utiliza **hiperparâmetros pré-definidos (fixos)** e consegue um ótimo desempenho em muitos *datasets*

Ferramenta	Acurácia	Recall	Tempo
AutoGluon	0,98	0,98	00:00:13
Auto-Sklearn	0,98	0,99	00:02:00

AutoML: pipeline almejado






ACADEMY

Conference


AutoML: Transparência e Interpretabilidade

Foco inicial: **compreender**
melhor as **ferramentas** de
AutoML e os **resultados**

AutoML: transparência (transversal)



AutoML: transparência (transversal)



AutoML: transparência

```
INFO: [2023-10-08 18:35] Preprocessing data...
INFO: Remove Outliers...
INFO: Remove Duplicates...
WARNING: [No columns with cryptographic signatures found.]
INFO: Remove Missing Values...
INFO: OneHotEncoder...
INFO: LabelEncode...
INFO: [2023-10-08 18:35] Performing feature selection
INFO: See the selected features at: results\Features_Selected_202
```

```
INFO: [2023-10-08 18:35] Optimizing hyperparameters...
INFO: See the Models Ranking and Hyperparameters Results at: resu
INFO: Best Model: DecisionTreeClassifier, Best Parameters: {'ccp_
s_weight': None, 'criterion': 'gini', 'max_depth': 10, 'max_featur
eaf_nodes': None, 'min_impurity_decrease': 0.0, 'min_samples_leaf':
_split': 2, 'min_weight_fraction_leaf': 0.0, 'random_state': 42, 'splitter': 'best
}
```

```
INFO: See your Best Model at: results\best_model_20231008_183457.pkl
INFO: [2023-10-08 18:39] Evaluating model...
INFO: Accuracy:0.95
INFO: Precision:0.95
INFO: Recall:0.91
INFO: F1-Score:0.93
```


Saídas da MH-AutoML:

- melhor modelo
- características selecionadas
- hiperparâmetros
- *ranking* dos modelos




- best_model_20231004_162724.pkl
- Features_Selected_20231004_162902.csv
- Hyperparameters_Results_20231004_1630...
- interpretability_20231004_162724.html
- Models_Ranking_20231004_163005.csv.csv

AutoML: interpretabilidade




AutoML: interpretabilidade

Prediction probabilities



Utilizar
frameworks como
LIME e SHAP
para produzir
explicações
independentes de
modelo



Feature	Value
SEND_SMS	0.00
GET_ACCOUNTS	0.00
WRITE_HISTORY_BOOKMARKS	0.00
READ_SMS	0.00
WRITE_SMS	0.00
USE_CREDENTIALS	0.00
READ_PHONE_STATE	0.00
RECEIVE_SMS	0.00
MANAGE_ACCOUNTS	0.00

AutoML: interpretabilidade

SHAP: características que mais contribuem para a predição

Weight	Feature
0.0865 ± 0.0067	SEND_SMS
0.0149 ± 0.0037	GET_ACCOUNTS
0.0146 ± 0.0022	READ_PHONE_STATE
0.0097 ± 0.0011	ACCESS_LOCATION_EXTRA_COMMANDS
0.0081 ± 0.0023	READ_SMS
0.0056 ± 0.0018	RECEIVE_BOOT_COMPLETED
0.0054 ± 0.0023	WAKE_LOCK
0.0043 ± 0.0009	WRITE_HISTORY_BOOKMARKS
0.0029 ± 0.0005	DELETE_CACHE_FILES
0.0028 ± 0.0012	READ_EXTERNAL_STORAGE
0.0024 ± 0.0007	VIBRATE
0.0021 ± 0.0018	USE_CREDENTIALS
0.0021 ± 0.0003	BIND_WALLPAPER
0.0021 ± 0.0009	CHANGE_WIFI_STATE
0.0019 ± 0.0007	INTERNET
0.0017 ± 0.0006	READ_LOGS
0.0017 ± 0.0022	CAMERA
0.0015 ± 0.0017	MANAGE_ACCOUNTS
0.0013 ± 0.0005	WRITE_APN_SETTINGS
0.0012 ± 0.0009	BLUETOOTH

... 93 more ...




AutoML: interpretabilidade

XAI: um estudo de caso
com múltiplos *datasets*




AutoML: interpretabilidade




dataset
Drebin-215

AutoML: interpretabilidade



AutoML: interpretabilidade



dataset
KronoDroid

AutoML: interpretabilidade


Insights:

- Não há interseção direta entre os *datasets*
- Importância de utilizar e avaliar múltiplos *datasets*
- Papel das características criadas por especialistas

APICall:...:getattributerésourcevalue()




APICall:...:setcustom...



Insight!

AutoML: pipeline





Tempest

ACADEMY

Conference

AML: ações transversais

Foco inicial: **impacto** de
ataques de ***label flipping***
(LFA) em *datasets*
rotulados

AML: *Label Flipping Attacks* (LFA)

Ataques de Mudança de Rótulo no Contexto da Detecção de Malwares Android: Uma Análise Experimental



LFA:

- Aleatório
- Entropia
- Silhueta

AML: Label Flipping Attacks (LFA)

Dataset	Classif.	Ruído (%)						MCC baseline
		5	10	15	20	25	30	
AndroCrawl_v1	SVM	0,8445	0,6331	0,4856	0,3811	0,2238	0,0543	0,9095
	RF	0,7688	0,6050	0,4916	0,3893	0,2442	0,0743	0,9099
	DT	0,6777	0,5566	0,4692	0,3705	0,2350	0,0675	0,8765
AndroCrawl_v2	SVM	0,6747	0,5354	0,4459	0,3698	0,2831	0,1752	0,8570
	RF	0,6713	0,5311	0,4380	0,3622	0,2667	0,1552	0,8513
	DT	0,6476	0,5170	0,4254	0,3622	0,2667	0,1552	0,8321
Adroit	SVM	0,6472	0,6034	0,5555	0,5077	0,4607	0,4137	0,7316
	RF	0,5295	0,4976	0,4874	0,4799	0,4722	0,4645	0,5989
	DT	0,5196	0,4869	0,5209	0,4831	0,4459	0,4087	0,5713
DefenseDroid	SVM	0,8262	0,7154	0,5831	0,4607	0,3384	0,2161	0,8389
	RF	0,8186	0,7306	0,6098	0,5077	0,4054	0,3031	0,8458
	DT	0,7095	0,6389	0,5447	0,4607	0,3384	0,2161	0,7951

Ideia do impacto
do LFA silhueta
nos modelos
SVM, RF e DT

AML: *Label Flipping Attacks* (LFA)

Resultados:

- LFA **aleatório** foi o **menos impactante**
- LFA **silhueta** foi o **mais impactante**
- Modelo **SVM** é mais **robusto** (aleatório e entropia)
- Modelo **RF** é **menos impactado** pelo **silhueta**
- *Dataset* **Drebin-215** foi **menos impactado**

AML: *Label Flipping Attacks* (LFA)



Há ***datasets*** mais "resistentes" a ataques adversariais como LFA?
Quais **características** deixam o *dataset* menos suscetível a ataques adversariais?

Quais são os **modelos menos suscetíveis** aos ataques adversariais?

...



Tempest

ACADEMY

Conference

FIM?

Ou apenas o início do meio
de uma longa jornada?

Considerações finais

Existem vários **desafios em todos os estágios** do pipeline de AutoML



Considerações finais

Existem vários **desafios em todos os estágios** do pipeline de AutoML

Adicionar **transparência e interpretabilidade** é fundamental para **compreender** os resultados e **comparar** as diferentes soluções de AutoML



Considerações finais

Existem vários **desafios em todos os estágios** do pipeline de AutoML

Adicionar **transparência e interpretabilidade** é fundamental para **compreender** os resultados e **comparar** as diferentes soluções de AutoML

Há **muitos desafios** no domínio de **detecção de malwares Android**

- remoções manuais de malwares ainda são frequentes





Tempest

ACADEMY

Conference
2023

Ask the Experts

Venha conversar

Diego Kreutz

diegokreutz@unipampa.edu.br

